

Analisi di Clustering — Documentazione Tecnica

Data Scientist: Diego Miccoli

9 ottobre 2025

Sommario

Questa relazione sintetizza i risultati dell'analisi di clustering condotta su quattro blocchi logici di feature (Demografia, Comportamento, Utilizzo, Transazioni). Nel notebook sono stati testati due algoritmi principali (KMeans e DBSCAN). Solo i blocchi *Utilizzo* e *Transazioni* hanno restituito partizionamenti interpretabili e significativi: per **Utilizzo** si focalizza l'attenzione sul risultato KMeans ($k=2$); per **Transazioni** sono discussi sia KMeans ($k=2$) sia DBSCAN (3 cluster). Il documento riporta le statistiche aggregate, le metriche di qualità e una interpretazione tecnica dei raggruppamenti, compresa una proposta di denominazione coerente con le feature rilevanti.

1 Premessa e obiettivi

L'obiettivo dell'analisi è identificare segmenti di clientela omogenei, utili per azioni di marketing mirate, gestione del rischio e monitoraggio del churn. I blocchi di feature sono stati scelti per separare aspetti: (i) anagrafici, (ii) comportamentali, (iii) utilizzo del credito e (iv) comportamento transazionale. In questa relazione si riportano esclusivamente i risultati utili alla business review: **Utilizzo** e **Transazioni**.

2 Metodologia

2.1 Preprocessing

Le feature numeriche sono state scalate con `StandardScaler`; le variabili categoriche, quando presenti, sono state codificate tramite `OneHotEncoder`. Per le visualizzazioni esplorative è stata valutata una riduzione dimensionale (PCA / t-SNE) al fine di verificare la separabilità dei cluster.

2.2 Algoritmi e metriche

Sono stati applicati:

- KMeans (ricerca del k ottimale con silhouette e verifica delle metriche interne);
- DBSCAN (ricerca eps tramite percentili delle distanze e valutazione di rumore/outlier).

Metriche calcolate: Silhouette score, Davies-Bouldin index, Calinski-Harabasz index. Per ciascun cluster sono riportate: dimensione, numero di clienti churned e churn rate, e medie delle feature di interesse.

3 Risultati

3.1 Blocco: Utilizzo (KMeans)

Panoramica: feature utilizzate: `Credit_Limit`, `Total_Revolving_Bal`, `Avg_Open_To_Buy`, `Avg_Utilization_L`
KMeans ha identificato $k = 2$ cluster con metriche di qualità:

- Silhouette: 0.469
- Davies-Bouldin: 0.871
- Calinski-Harabasz: 7474.6

3.1.1 Statistiche aggregate

Tabella 1: Statistiche base dei cluster — Utilizzo (KMeans)

Cluster	Size	Churned	Churn_Rate	Note
0	1994	296	0.1484	<i>Cluster 0: alto limite, basso utilizzo</i>
1	8133	1331	0.1637	<i>Cluster 1: basso limite, utilizzo maggiore</i>

3.1.2 Medie feature — Utilizzo

Tabella 2: Medie delle feature principali — Utilizzo

Cluster	Credit_Limit	Total_Revolving_Bal	Avg_Open_To_Buy	Avg_Utilization_Ratio
0	24 672.67	1117.22	23 555.45	0.05
1	4699.19	1173.99	3525.19	0.33
Media generale	8631.95	1162.81	7469.14	0.27

3.1.3 Interpretazione e denominazione

I due gruppi risultano distinti principalmente per la **capacità di credito disponibile** e per la **percentuale di utilizzo medio della carta**:

- **Cluster 0 — “Alta disponibilità, basso utilizzo”**: clienti con *Credit_Limit* significativamente superiore alla media (+186%), alta disponibilità residua (*Avg_Open_To_Buy*) e un basso tasso di utilizzo medio (*Avg_Utilization_Ratio* = 0.05). Questi clienti presentano un churn leggermente inferiore rispetto al cluster 1.
- **Cluster 1 — “Bassa disponibilità, utilizzo relativo elevato”**: clienti con *Credit_Limit* inferiore alla media (-45.6%), ma con una *Avg_Utilization_Ratio* più elevata (0.33). Potrebbero corrispondere a clienti che utilizzano maggiormente la linea di credito disponibile.

Osservazione operativa: il cluster 1 mostra un churn rate marginalmente superiore (0.1637 vs 0.1484) — suggerisce che un utilizzo relativamente più alto, soprattutto su limiti inferiori, potrebbe essere associato a un rischio leggermente maggiore di abbandono.

3.2 Blocco: Transazioni

Panoramica: feature utilizzate: `Total_Trans_Amt`, `Total_Trans_Ct`, `Total_Amt_Chng_Q4_Q1`, `Total_Ct_Chng_Q4_Q1`. Entrambi gli algoritmi hanno fornito partizionamenti interpretativi: KMeans (k=2) e DBSCAN (eps=0.6009, min_samples=5) con 3 cluster e rumore.

3.2.1 KMeans (k=2)

Metriche di qualità KMeans:

- Silhouette: 0.408
- Davies-Bouldin: 0.878
- Calinski-Harabasz: 3705.0

Tabella 3: Statistiche base dei cluster — Transazioni (KMeans)

Cluster	Size	Churned	Churn_Rate	Nota
0	8916	1544	0.1732	<i>Clienti transazionali ordinari</i>
1	1211	83	0.0685	<i>Clienti ad alto volume/frequenza</i>

Tabella 4: Medie delle feature principali — Transazioni (KMeans)

Cluster	Total_Trans_Amt	Total_Trans_Ct	Total_Amt_Chng_Q4_Q1	Total_Ct_Chng_Q4_Q1
0	3342.13	59.74	0.76	0.71
1	12 222.76	102.57	0.78	0.72
Media generale	4404.09	64.86	0.76	0.71

3.2.2 Interpretazione e denominazione — KMeans

- **Cluster 0** — “**Spender Moderato / Base**”: la maggioranza dei clienti (n=8916) con valore e frequenza di transazioni sotto o vicino alla media. Churn rate osservato: 17.32%.
- **Cluster 1** — “**Spender Intensivo**”: segmento più piccolo (n=1211) con importi totali e conteggio transazioni sensibly superiori alla media (+177% ammontare, +58% conteggio). Il churn rate è molto più basso (6.85%), indicando maggiore fedeltà.

3.2.3 DBSCAN (eps=0.6009, min_samples=5)

DBSCAN ha trovato 3 cluster (+ segmento di rumore) con metriche:

- Silhouette: 0.480
- Davies-Bouldin: 1.611
- Calinski-Harabasz: 1615.1
- Cluster trovati: 3; Punti di rumore: 144 (1.4%)

Tabella 5: Medie delle feature principali — Transazioni (DBSCAN)

Cluster	Size	Total_Trans_Amt	Total_Trans_Ct	Note
0	9231	3600.70	61.62	<i>Base / stabile</i>
1	11	1628.18	31.91	<i>Molto basso ma alta variazione Q4 vs Q1 (anomalie)</i>
2	741	14 702.29	110.39	<i>Top Spenders / Alto valore</i>
-1	144	-	-	<i>Punti di rumore / outlier</i>

3.2.4 Interpretazione e denominazione — DBSCAN

- **Cluster 0 — “Stable Core”**: ampia porzione della popolazione con attività transazionale sotto la media; rappresenta il comportamento transazionale tipico.
- **Cluster 1 — “Anomali / Alta variazione”**: gruppo molto piccolo (n=11) caratterizzato da forti variazioni tra Q4 e Q1; potenziali anomalie o casi da investigare (es. errori di registrazione o eventi eccezionali).
- **Cluster 2 — “Top Spenders”**: clienti con importi e conteggi di transazioni significativamente più alti della media; target ideale per programmi di retention premium.

4 Discussione

- I risultati mostrano coerenza tra KMeans e DBSCAN per il blocco transazioni: entrambi evidenziano un grande gruppo “base/stabile” e un gruppo con attività significativamente più elevata. DBSCAN aggiunge valore individuando piccoli sottogruppi atipici e outlier.
- Per il blocco utilizzo il risultato KMeans (2 cluster) è solido (silhouette 0.469) e interpretabile; DBSCAN non ha prodotto una soluzione utile per questo blocco (risultati sparsi).
- L’analisi del churn per cluster suggerisce che i *Top Spenders* e i clienti con *alta disponibilità e basso utilizzo* hanno churn inferiore rispetto alla media, mentre segmenti con uso più intenso su limiti ridotti mostrano rischio leggermente superiore.

5 Conclusioni

- Utilizzare i cluster identificati come base per campagne di retention differenziate: ad esempio, offerte premium e programmi fedeltà per i *Top Spenders*; incentivi alla stabilità per i “Bassa disponibilità / utilizzo elevato”.