

Analisi dell'abbandono bancario



Progetto per il corso di Data Mining

Diego Miccoli
11 ottobre 2025

Indice

1	Introduzione	2
1.1	Descrizione delle fasi del processo CRISP-DM	2
2	Comprensione del Contesto Aziendale	4
2.1	Definizione degli Obiettivi di Business	4
2.2	Valutazione della Situazione Attuale	4
2.3	Definizione degli Obiettivi sui Dati	5
2.4	Elaborazione del Piano di Progetto	5
3	Comprensione dei Dati	7
3.1	Raccolta Iniziale dei Dati	7
3.2	Descrizione dei Dati	7
3.3	Descrizione del dataset	7
3.3.1	Elenco e descrizione delle variabili	8
3.4	Esplorazione dei Dati	9
3.5	Analisi delle distribuzioni diversificate per abbandono	13
3.6	Analisi bivariata con riferimento all'abbandono	17
3.7	Verifica della Qualità dei Dati	24
4	Preparazione dei Dati	26
4.1	Descrizione del Dataset	26
4.2	Selezione dei Dati	26
4.3	Pulizia dei Dati	26
4.4	Costruzione dei Dati	27
4.5	Formattazione dei Dati	27
5	Modellazione dei Dati	28
5.1	Selezione delle Tecniche di Modellazione	28
5.2	Progettazione del Piano di Test	29
5.3	Costruzione del Modello	30
5.4	Valutazione del Modello	30
6	Valutazione	31
6.1	Valutazione dei Risultati	31
6.2	Revisione del Processo	38
6.3	Definizione dei Prossimi Passi	38
7	Conclusioni	39

Capitolo 1

Introduzione

Questo progetto è stato realizzato dopo aver seguito il corso di Data Mining presso l'Università Aldo Moro di Bari erogato nella formazione del corso di laurea in Data Science. L'obiettivo principale è quello di mettere in pratica le tecniche di analisi e progettazione affrontate durante il corso e applicarle in un contesto reale ove i risultati estratti possano essere a sostegno dell'azienda.

Per mettere in pratica le conoscenze acquisite è stato scelto un problema in campo finanziario/bancario e l'analisi ha richiesto di entrare in confidenza con la terminologia del settore per meglio comprendere il problema e come affrontarlo nel migliore dei modi. Il problema principale posto è quello di riuscire a prevedere l'abbandono dell'istituto bancario da parte del cliente e quindi riuscendo a percepire i cambiamenti che possano condurre un determinato cliente a optare per l'abbandono e in questa situazione di rischio provare a intervenire con misure mirate verso il cliente per fargli riacquisire fiducia nell'istituto bancario. Per raggiungere tale obiettivo sono state fatte delle analisi per comprendere meglio le abitudini dei clienti e il loro comportamento finanziario e i risultati sono stati opportunamente documentati e confrontati nelle sezioni di questa documentazione.

1.1 Descrizione delle fasi del processo CRISP-DM

Il progetto segue la metodologia CRISP-DM (Cross-Industry Standard Process for Data Mining), una delle più diffuse per la realizzazione di progetti di data mining. Essa si compone di sei fasi principali, ciascuna delle quali è rappresentata da un capitolo del presente documento:

- **Comprensione del business (Business Understanding)**

In questa fase si analizza il contesto aziendale, si definiscono gli obiettivi del progetto in termini di business e si stabiliscono i criteri per valutare il successo. Comprendere appieno il problema da risolvere è essenziale per guidare le successive attività analitiche.

- **Comprensione dei dati (Data Understanding)**

Dopo aver raccolto i dati iniziali, si procede con l'esplorazione preliminare per valutarne struttura, qualità e coerenza. L'obiettivo è individuare eventuali problemi (dati mancanti, anomalie, outlier) e acquisire una visione generale utile alla fase di preparazione.

- **Preparazione dei dati (Data Preparation)**

Questa fase include tutte le attività necessarie per ottenere un dataset "modellabile". Prevede la selezione delle variabili rilevanti, la pulizia dei dati, la costruzione di nuove feature, l'integrazione di fonti e la formattazione finale in vista della modellazione.

- **Modellazione (Data Modelling)**

Si selezionano e applicano tecniche di modellazione (es. classificazione, regressione, clustering) per costruire modelli predittivi o descrittivi. È fondamentale anche definire una strategia di test per valutare le prestazioni dei modelli in modo oggettivo.

- **Valutazione (Evaluation)**

In questa fase si confrontano i risultati dei modelli con gli obiettivi di business iniziali. Si valuta l'efficacia dell'intero processo di data mining e si determinano eventuali aggiustamenti prima della distribuzione.

- **Distribuzione (Deployment)**

Le conoscenze ottenute vengono messe a disposizione degli stakeholder attraverso report, dashboard o sistemi automatizzati. Viene inoltre pianificato il monitoraggio del modello nel tempo e la sua eventuale manutenzione.

Seguendo questa metodologia di lavoro abbiamo affrontato il problema posto e preso in esame le varie soluzioni per evitare o ridurre il tasso di abbandono dei clienti. Di seguito andremo a prendere visione dei passi svolti e dei risultati ottenuti per ogni step.

Capitolo 2

Comprensione del Contesto Aziendale

2.1 Definizione degli Obiettivi di Business

Il progetto nasce dall'esigenza di comprendere e ridurre il fenomeno dell'abbandono della clientela presso un istituto bancario. Il contesto di riferimento è un ambiente competitivo in cui la fidelizzazione dei clienti rappresenta un elemento strategico per la sostenibilità e la crescita della banca. I dati utilizzati derivano da un database interno che raccoglie informazioni comportamentali, demografiche e transazionali dei clienti, offrendo una base solida per un'analisi approfondita.

L'obiettivo principale è duplice: da un lato identificare i fattori che influenzano maggiormente la propensione all'abbandono (churn), dall'altro sviluppare strumenti predittivi e descrittivi per migliorare la comprensione dei diversi profili di clientela. L'analisi intende fornire insight utili alla definizione di strategie mirate di retention e all'ottimizzazione delle campagne di marketing relazionale.

Il successo del progetto sarà misurato in termini di miglioramento della capacità predittiva del modello di churn, di individuazione di pattern comportamentali rilevanti e della possibilità di tradurre i risultati in azioni concrete a supporto delle decisioni aziendali.

2.2 Valutazione della Situazione Attuale

L'istituto bancario dispone di una base dati consolidata e ben strutturata, contenente informazioni sui clienti attivi e disattivati. Le risorse analitiche comprendono strumenti software di analisi statistica e machine learning (Python, scikit-learn, R, librerie di data mining), oltre a competenze interne nel campo della data science e della gestione della conoscenza.

Tra le principali assunzioni di progetto si ipotizza la coerenza e l'affidabilità dei dati

storici, nonché la rappresentatività dei campioni analizzati. I vincoli riguardano la riservatezza dei dati, la disponibilità temporale delle informazioni e la necessità di interpretare i risultati nel rispetto delle normative bancarie e della privacy.

I rischi principali includono la possibile presenza di variabili ridondanti o rumorose, la distorsione dovuta a dati sbilanciati e l'eventuale difficoltà di tradurre i risultati analitici in azioni operative. Tali rischi saranno mitigati mediante tecniche di pulizia, bilanciamento dei dati e validazione incrociata dei modelli.

I costi del progetto si concentrano principalmente sul tempo e sulle risorse umane impiegate nelle fasi di preparazione e modellazione dei dati, mentre i benefici attesi consistono in una maggiore conoscenza del comportamento della clientela e in una riduzione del tasso di abbandono attraverso strategie di intervento mirate.

2.3 Definizione degli Obiettivi sui Dati

Gli obiettivi analitici si articolano in tre principali task di data mining:

1. Classificazione: costruzione di un modello predittivo per identificare i clienti a rischio di abbandono. Il successo di questo task verrà valutato mediante metriche di performance quali il *Recall* (prioritario per la natura sbilanciata del dataset), l'*F1-Score* e l'*ROC-AUC*. L'obiettivo è garantire un'elevata sensibilità nella rilevazione dei clienti churner minimizzando al contempo i falsi negativi.

2. Cluster Analysis: individuazione e descrizione di gruppi omogenei di clienti accomunati da caratteristiche e comportamenti simili. Tale analisi permette di riconoscere tipologie di clientela con diversa propensione all'abbandono e di delineare strategie differenziate di retention. La bontà dei raggruppamenti sarà misurata tramite il *Silhouette Score* e l'interpretabilità economico-comportamentale dei cluster.

3. Frequent Pattern Mining: ricerca di pattern e regole associative tra variabili comportamentali e demografiche per evidenziare combinazioni ricorrenti legate all'abbandono. I criteri di selezione dei pattern saranno un supporto minimo del 3% e una confidenza superiore all'80%, in modo da garantire rilevanza statistica e operativa dei risultati.

2.4 Elaborazione del Piano di Progetto

Il progetto seguirà le fasi del processo CRISP-DM: comprensione del business, comprensione dei dati, preparazione, modellazione, valutazione e deployment. Le attività saranno pianificate in modo iterativo, consentendo la revisione delle ipotesi e il miglioramento continuo dei modelli.

Le tempistiche prevedono una prima fase di esplorazione e pulizia dei dati, seguita dalla modellazione dei task di classificazione e clustering, per concludersi con l'identificazione di pattern associativi e la definizione di raccomandazioni operative. Gli strumenti previsti includono linguaggi di programmazione Python e R, ambienti Jupyter Notebook e librerie di machine learning e data mining come scikit-learn, pandas, numpy e mlxtend.

La valutazione iniziale delle tecniche conferma la validità dell'approccio misto (supervisionato e non supervisionato) per massimizzare la comprensione del fenomeno di churn e supportare l'istituto bancario nello sviluppo di strategie proattive di gestione della clientela.

Capitolo 3

Comprensione dei Dati

3.1 Raccolta Iniziale dei Dati

Le fasi di raccolta sono state eseguite da terzi, tramite database della banca, estratto di un determinato periodo con le relative attività dei clienti. Queste informazioni sono pervenute nelle nostre mani in forma di file csv e sono state sottoposte ad attenta analisi esplorativa e descrittiva.

3.2 Descrizione dei Dati

L'EDA è una fase critica per comprendere la qualità dei dati e orientare le successive fasi di modellazione (feature engineering, selezione delle variabili, scelta degli algoritmi). Il dataset analizzato contiene informazioni anagrafiche, creditizie e transazionali dei clienti. Le analisi sono finalizzate a identificare distribuzioni anomale, outlier, correlazioni forti e relazioni con la variabile di interesse `Attrition_Flag` (churn).

3.3 Descrizione del dataset

- Numero di osservazioni: 10127 (*vedi notebook*)
- Numero di variabili: 21 (numeriche e categoriche).
- File sorgente: `BankChurners.csv`

3.3.1 Elenco e descrizione delle variabili

Di seguito si riporta l'elenco completo delle variabili presenti nel dataset con una breve descrizione tecnica e il tipo di trattamento consigliato.

Variabile	Tipo	Descrizione e trattamento consigliato
Customer_Age	Numerica:int	Età del cliente (anni). Trattamento: scaling, possibile binning per analisi categorie.
Gender	Categorica:str[2val]	Sesso del cliente (M/F). One-hot encoding per modelli.
Dependent_count	Numerica:int	Numero di persone a carico. Trattamento: numerica o categorizzazione se necessario.
Education_Level	Categorica:str[7val]	Livello di istruzione. One-hot encoding o embedding.
Marital_Status	Categorica:str[4val]	Stato civile. One-hot encoding.
Income_Category	Categorica:str[6val]	Fascia di reddito. Attenzione a categorie 'Unknown'.
Card_Category	Categorica:str[4val]	Tipologia di carta (Blue, Silver, ...).
Months_on_book	Numerica:int	Tenure con l'istituto (mesi). Utile come proxy della fidelizzazione.
Total_Relationship_Count	Numerica:int	Numero di prodotti/relazioni attive col cliente.
Months_Inactive_12_mon	Numerica:int	Numero di mesi inattivi negli ultimi 12 mesi.
Contacts_Count_12_mon	Numerica:int	Numero di contatti con la banca in 12 mesi.
Credit_Limit	Numerica:float	Limite di credito assegnato. Distribuzione tipicamente asimmetrica: scaling log può aiutare.
Total_Revolving_Bal	Numerica:float	Saldo revolving (debito rotante).
Avg_Open_To_Buy	Numerica:float	Disponibilità media residua.
Total_Trans_Amt	Numerica:float	Ammontare totale delle transazioni (periodo osservato).
Total_Trans_Ct	Numerica:int	Numero totale di transazioni.
Total_Amt_Chng_Q4_Q1	Numerica_float	Variazione dell'ammontare totale tra Q4 e Q1. Utile per trend.
Total_Ct_Chng_Q4_Q1	Numerica:float	Variazione del conteggio transazioni tra Q4 e Q1.
Avg_Utilization_Ratio	Numerica_float	Rapporto medio di utilizzo della carta (uso/limite). Valore in [0,1].
Attrition_Flag	Categorica:str[2val]	Target: 'Existing Customer' vs 'Attrited Customer'. Variabile di interesse per churn.
N_client	Categorico:[unique]	codice univoco del cliente da eliminare.

Andiamo a prendere visione delle principali statistiche descrittive dei dati per avere un'idea generale di come essi si comportino e si distribuiscano non che per capire l'estensione nei domini di ogni variabile analizzata.

	count	mean	std	min	25%	50%	75%	max
Customer_Age	10127.0	46.33	8.02	26.0	41.00	46.00	52.00	73.00
Dependent_count	10127.0	2.35	1.30	0.0	1.00	2.00	3.00	5.00
Months_on_book	10127.0	35.93	7.99	13.0	31.00	36.00	40.00	56.00
Total_Relationship_Count	10127.0	3.81	1.55	1.0	3.00	4.00	5.00	6.00
Months_Inactive_12_mon	10127.0	2.34	1.01	0.0	2.00	2.00	3.00	6.00
Contacts_Count_12_mon	10127.0	2.46	1.11	0.0	2.00	2.00	3.00	6.00
Credit_Limit	10127.0	8631.95	9088.78	1438.3	2555.00	4549.00	11067.50	34516.00
Total_Revolving_Bal	10127.0	1162.81	814.99	0.0	359.00	1276.00	1784.00	2517.00
Avg_Open_To_Buy	10127.0	7469.14	9090.69	3.0	1324.50	3474.00	9859.00	34516.00
Total_Amt_Chng_Q4_Q1	10127.0	0.76	0.22	0.0	0.63	0.74	0.86	3.40
Total_Trans_Amt	10127.0	4404.09	3397.13	510.0	2155.50	3899.00	4741.00	18484.00
Total_Trans_Ct	10127.0	64.86	23.47	10.0	45.00	67.00	81.00	139.00
Total_Ct_Chng_Q4_Q1	10127.0	0.71	0.24	0.0	0.58	0.70	0.82	3.71
Avg_Utilization_Ratio	10127.0	0.27	0.28	0.0	0.02	0.18	0.50	1.00

Figura 3.1: Statistiche sulle variabili numeriche.

	count	unique	top	freq
Attrition_Flag	10127	2	Existing Customer	8500
Gender	10127	2	F	5358
Education_Level	10127	7	Graduate	3128
Marital_Status	10127	4	Married	4687
Income_Category	10127	6	Less than \$40K	3561
Card_Category	10127	4	Blue	9436

Figura 3.2: Statistiche sulle variabili categoriche.

3.4 Esplorazione dei Dati

Partiamo con l'analisi univariata. Per le variabili numeriche sono stati prodotti istogrammi e statistiche descrittive (mean, std, skewness, kurtosis). Di seguito sono inseriti i segnaposto per le figure principali con commento interpretativo; sostituisci i file immagine con i tuoi rendimenti nel percorso indicato.




Figura 3.3: Distribuzione del reddito annuo.

Commento interpretativo: la distribuzione del reddito risulta fortemente asimmetrica (destra), con una maggioranza di clienti con redditi medio-bassi e una coda di clienti con redditi molto elevati.




Figura 3.4: Distribuzione degli abbandoni.

Commento interpretativo: la distribuzione del conteggio degli abbandoni è fortemente sbilanciata




Figura 3.5: Distribuzione del genere tra i clienti.

Commento interpretativo: C'è un leggero sbilanciamento verso il genere femminile, ma è di poco rilevante in linea di principio ci sono clienti in numero eguale nei due sessi.




Figura 3.6: Distribuzione della tipologia di carta del cliente.

Commento interpretativo: distribuzione asimmetrica, la maggiorparte dei clienti hanno carta blu, e solo in minor numero abbiamo delle diversificazioni di clienti premium.




Figura 3.7: Distribuzione dei contatti telefonici dal cliente verso la banca.

Commento interpretativo: la maggiorparte dei clienti contatta la banca dalle 2 alle 3 volte e solo pochi clienti necessitano contatti superiori ai 4 o inesistenti.




Figura 3.8: Distribuzione del numero dei prodotti finanziari attivi.

Commento interpretativo: i clienti in maggioranza tendono ad aprire più di 2 prodotti finanziari.




Figura 3.9: Distribuzione del numero di persone a carico.

3.5 Analisi delle distribuzioni diversificate per abbandono

Questa sezione contiene figure e commenti sulle distribuzioni per variabili continue suddivise e confrontate rispetto al churn (`Attrition_Flag`). L'obiettivo è capire se i clienti che abbandonano si comportano e hanno comportamenti differenti dai clienti che non abbandonano e capire quanto siano significative queste differenze.




Figura 3.10: Confronto tra churn (`Attrition_Flag`) e `Total_Trans_Amt`.

Commento interpretativo: tipicamente i clienti con maggior valore transazionale mostrano churn inferiore: la figura aiuta a verificare questa ipotesi (esaminare mediana e dispersione per ciascun gruppo). Qualsiasi differenza significativa nelle medie o mediane suggerisce valore predittivo per modelli di churn.




Figura 3.11: Distribuzione di `Avg_Utilization_Ratio` per status di churn.

Commento interpretativo: l'uso relativo del credito può essere associato al rischio di abbandono; la figura mostra se i clienti churned hanno, in media, utilizzi più elevati (indicatore di stress finanziario) o più bassi.




Figura 3.12: Distribuzione di `Total_Trans_Ct` per status di churn.

Commento interpretativo: Qui analizzando le distribuzioni rispetto al numero totale di transazioni, possiamo notare come i clienti che abbandonano hanno media e media inferiori alla distribuzioni di chi non abbandona.




Figura 3.13: Distribuzione di Total_Revolving_Bal per status di churn.

Commento interpretativo: analizzato il credito rinnovabile riusciamo a cogliere un informazione di dettaglio, metre gli utenti che non abbandonano hanno media e media più alte di chi abbandona, notiamo che la distribuzione di chi non abbandona è fortemente sbilanciata verso un alta rinnovabilità del credito, mentro la distribuzione di chi abbandona è fortemente sbilanciata verso un credito rinnovabile pressapoco nullo il quale potrebbe essere un forte indicatore dell'abbandono.




Figura 3.14: Distribuzione di `Contact_Count_12_mon` per `statusdichurn`.

Commento interpretativo: rispetto ai contatti telefonici da parte dei clienti alla banca, non ci sono significative differenze le due distribuzioni sono simili con più picchi modali, tuttavia rispetto al' abbandono tali clienti hanno media e mediana dei contatti più elevata rispetto a chi non abbandona.




Figura 3.15: Distribuzione di `Month_Inactive_12_mon` per `statusdichurn`.

Commento interpretativo: Nel caso dell'inattività della carta vediamo che per i clienti che abbandonano media e mediana sono più alte e la distribuzione è spo-

stata verso un maggiore numero di mesi di inattività rispetto ai clienti che non abbandonano.

3.6 Analisi bivariata con riferimento all'abbandono

Questa sezione contiene figure principalmente scatter plot a 2 dimensioni e commenti inerenti le osservazioni e come esse si dispongano nello spazio bidimensionale evidenziando il churn (**Attrition_Flag**) per distinguere le osservazioni. L'obiettivo è capire se i clienti che abbandonano si comportano e hanno comportamenti differenti dai clienti che non abbandonano e se queste differenze portino ad occupare diverse zone dello spazio bidimensionale.




Figura 3.16: Relazione tra `Credit_Limit` e `Total_Trans_Amt` (scatter + smoothing).

Commento interpretativo: Qui vediamo che i clienti con alte transazioni non abbandonano e distinguiamo 3 fasce prevalenti per transazioni in base all'ammontare 0-5000, 7000-11000 e 12500-18000, con un netto abbandono nella prima fascia di transazioni con limite del credito sotto 15000.




Figura 3.17: Relazione tra `Credit_Limit` e `Total_Revolving_Bal` (scatter + smoothing).

Commento interpretativo: Dallo scatter possiamo mettere in evidenza un andamento curioso dell'abbandono che marca un credito inferiore ai 2000 indipendentemente dal saldo rinnovabile e evidenzia 2 picchi uno di quasi esclusivo abbandono per saldo rinnovabile nullo e l'altro diversificato per saldo rinnovabile massimo.




Figura 3.18: Relazione tra `Credit_Limit` e `Total_Trans_Ct` (scatter + smoothing).

Commento interpretativo: si evince una zona netta di abbandono ovvero clienti

con credito inferiore ai 10000 e numero di transazioni inferiore ai 60, altro dato curioso e che i clienti con credito massimo 35000, segnalano una netta presenza di abbandoni con transazioni inferiori a 80.




Figura 3.19: Relazione tra Total_Trans_Ct e Total_Revolving_Bal (scatter + smoothing).

Commento interpretativo: Qui si notano due zone di particolare interesse che ha un saldo rinnovabile nullo oppure chi lo ha massimo a 2500, inoltre c'è una buona distinzione rispetto al numero totale delle transazioni caratterizzando chi supera le 60 transazioni come clienti che restano, mentre al di sotto c'è una omogeneità tra chi resta e chi abbandona.




Figura 3.20: Relazione tra `Total_Trans_Amt` e `Total_Amt_Chng_Q4_Q1` (scatter + smoothing).

Commento interpretativo: Lo scatter mette in evidenza che clienti con alte transazioni tra 12500 e 18000 non abbandonano, mentre per le altre 2 fasce di transazioni da 7000 a 11000 e da 0 a 5000, l'abbandono è omogeneo nella fascia 7000-11000, mentre differente nell'ultima fascia di analisi dove un cambiamento del ammontare delle transazioni nel quadrimestre diversifica chi abbandona da chi resta.




Figura 3.21: Relazione tra `Total_Trans_Ct` e `Total_Trans_Amt` (scatter + smoothing).

Commento interpretativo: Dallo scatter possiamo cogliere chiaramente le zone di interesse. Iniziamo con osservare che rispetto all'ammontare totale le osservazioni si dividono naturalmente in 3 gruppo, da 0 a 5000, da 7000 a 11000 e da 12500 a 18000. Curioso è inoltre aspetto di totale assenza di abbandono nei clienti con alti importi transazionali, mentre negli altri gruppi di transazioni osserviamo che se il numero delle trasazioni è basso c'è una netta tendenza all'abbandono, metre se alto i clienti non abbandonano.




Figura 3.22: Relazione tra Avg_Utilization_Ratio e Total_Revolving_Bal (scatter + smoothing).

Commento interpretativo: Dallo scatter si evincono due zone di interesse per l'analisi dei dati la prima in basso a sinistra ritaglia un piccola regione a prevalenza di clienti che abbandonano caratterizzati da utilizzi bassi e saldo rinnovabile basso, in questa zona a differenza delle altre c'è una netta prevalenza di abbandono, il fenomeno si ripete per i clienti con alto saldo rinnovabile ma senza alcuna distinzione rispetto all'utilizzo della carta.




Figura 3.23: Relazione tra Avg_Utilization_Ratio e Total_Revolving_Bal (scatter + smoothing).

Commento interpretativo: l'andamento della distribuzione segue un fascio di iperboli del quadrante positivo evidenziando che la curva dell'iperbole ha una netta prevalenza di abbandono.




Figura 3.24: Matrice di correlazione (variabili numeriche).

Commento interpretativo: la matrice di correlazione evidenzia coppie di variabili altamente correlate (valore assoluto vicino a 1). Queste relazioni possono indicare ridondanza informativa e suggerire aggregazione o rimozione di variabili per ridurre multicollinearità nei modelli lineari. Ad esempio, variabili come `Total_Trans_Amt` e `Total_Trans_Ct` possono essere correlate: se la correlazione è elevata, considerare l'uso di feature sintetiche (es. valore medio per transazione).




Figura 3.25: Matrice di correlazione di Cramer per variabili categoriche.

Commento interpretativo: la matrice di correlazione di Cramer mette in luce una forte correlazione tra.

L'analisi ha permesso di mettere in evidenza alcune caratteristiche dei dati che ci hanno permesso di comprendere meglio come i dati si comportano e variano rispetto alle feature che li caratterizzano. Chiramente in questo documento abbiamo messo in evidenza quelli che sono gli aspetti salienti e di maggiore interesse per l'analisi e per gli obbietivi posti nella precedente fase. Resta comunque disponibile la consultazione dell'analisi esplorativa completa con oltre 200 grafici che indagano le proprietà e caratteristiche dei dati. (si veda il file notebook jupyter *EDA_overture.ipynb*).

3.7 Verifica della Qualità dei Dati

- **Valori mancanti:** dopo analisi esplorativa si segnala l'assenza dei valori mancanti o incogruenti.
- **Feature inutilizzabili:** il codice cliente è una feature inutilizzabile che andrebbe solo a perturbare il modello in fase di addestramento senza alcuna

efficacia, lo stesso dicasi per gli indici previsti che non essendo chiari sono stati rimossi.

- **Outlier:** presenti su `Credit_Limit`, `Total_Trans_Amt` e `Total_Revolving_Bal`. Valutare trasformazioni (log), capping (winsorizing) o trattamento specifico per analisi di segmentazione.
- **Ridondanza:** se coppie di variabili risultano fortemente correlate, considerare la creazione di variabili aggregate o la rimozione per modelli che soffrono di multicollinearità.

I dati presenti nel csv sono di alta qualità, ma necessitaranno di adeguato preprocessing per le dovute tecniche e metodologie di data mining da applicare.

L'analisi esplorativa conferma la presenza di distribuzioni fortemente asimmetriche, oppure con più modalità dettagli che saranno tenuti in considerazione nell'utilizzo di tecniche di binning. Si evidenziano distribuzioni non eque nelle variabili categori come tipologia carta, lo stesso tasso di abbandono il numero dei contatti con la banca e dei prodotti finanziari. Infine si sono evidenziate delle forti multicolineartà che necessitano di una risoluzione prima di procedere con applicazione di tecniche di machine learning.

Capitolo 4

Preparazione dei Dati

4.1 Descrizione del Dataset

Il dataset ha 10127 record o righe e 21 features di tipo categorico e numerico, i dati sono in buona parte si veda la sezione di data understanding.

4.2 Selezione dei Dati

Dopo avere preso un'attenta visione dei dati abbiamo dovuto eliminare alcune feature per diversi motivi. Alcune sono state eliminate per inutilità della feature questo è il caso del codice cliente che risulta essenzialmente un indice univoco e quindi non utilizzabile. Seguono le variabili con multicollinearità che è stata evidenziata dall'analisi della correlazione. Quindi per le fasi di predizione su task di classificazione tali variabili sono state eliminate ovvero Gender, Avg_Open_to_Buy ovvero la disponibilità di spesa, il numero di transazioni totali e Customer_Age ovvero l'età del cliente, tuttavia queste variabili sono state utilizzate sia nei task di cluster analysis che in quelli di frequent pattern mining. Per quanto riguarda la selezione dei record, essi sono stati mantenuti tutti, in quanto totalmente integri e privi di missing values.

4.3 Pulizia dei Dati

La pulizia dei dati è avvenuta tramite rimozione degli outlier, con l'utilizzo del algoritmo basato sull'Intervallo Interquartile (IQR)** che risulta essere una tecnica statistica robusta e non parametrica (non assume una distribuzione specifica, come la Normale).

I concetti chiave per IQR outliers removal sono:

1. **Quartili:** Calcolo del Primo Quartile (Q_1) e del Terzo Quartile (Q_3).
2. **IQR:** L'Intervallo Interquartile è la dispersione del 50% centrale dei dati:

$$IQR = Q_3 - Q_1$$

3. **Limiti (Fences):** Vengono definiti un Limite Inferiore e un Limite Superiore (tipicamente usando il fattore $k = 1.5$) per identificare i valori anomali. Limite Inferiore = $Q_1 - 1.5 \times IQR$
 $LimiteSuperiore = Q_3 + 1.5 \times IQR$
4. **Outlier:** Tutti i punti dati che cadono al di fuori di questi limiti vengono classificati come outlier e possono essere rimossi o gestiti (e.g., tramite *capping*).

le feature principalmente affette da rumore degli outliers sono quelle numeriche continue. (si veda il relativo notebook per il trattamento)

4.4 Costruzione dei Dati

Durante le varie analisi sia esplorative che di pattern mining, i dati sono stati sottoposti a differenti tipi di elaborazioni che risultassero idonee per poter applicare le tecniche di cui ci siamo serviti. Innanzitutto per la cluster analysis i dati sono stati elaborati seguendo due principali strade standardizzazione delle feature numeriche e one hot encoding delle feature categoriche. Per il task di classificazione le feature sono state invece sottoposte a standardizzazione delle variabili numeriche continue, one hot encoding e ordinal encoding per le variabili con esplicito ordinamento dei valori questo per conservare l'informazione relativa all'ordine e in modo tale che il modello riesca a comprendere l'ordinamento. Infine per il task di frequent pattern mining le variabili sono state sottoposte a una pipeline più complessa di elaborazione che ha utilizzato inizialmente tecniche di binning equalwidth e equaldepth per andare a categorizzare le variabili numeriche continue, in seguito alla binnizzazione i tagli fatti sono stati sostituiti con nomi significativi quindi stringhe che intendificassero la categoria. Una volta ottenute le variabili categoriche da quelle numeriche si è adottato un processo di uno hot encoding seguito da booleanizzazione di tutte le feature ottenute in modo che i dati potessero essere compatibili con l'algoritmo di estrazione dei pattern frequenti. Alla fine di questo processo si è ottenuto un nuovo data frame con 113 feature di tipo booleano [vedasi nel dettaglio il notebook *FrequentPatternAnalysis.ipynb*].

4.5 Formattazione dei Dati

Una volta eseguite le pipeline di elaborazione dei dati questi sono stati salvati in nuovi csv, in modo da poterli riutilizzare per successive analisi in maniera più celere.

Capitolo 5

Modellazione dei Dati

5.1 Selezione delle Tecniche di Modellazione

Per cercare di modellare i dati ed estrarre da essi nuova conoscenza nonché con il fine ultimo di ottenere un modello predittivo, sono state messe in campo differenti modellazioni tesa ad affrontare i diversi obiettivi che ci siamo posti durante la fase di Business Understanding. Di seguito riportiamo le tecniche di modellazione usate per adempiere ai nostri scopi.

- Cluster Analysis: sono stati scelti come modelli per il ritrovamento di gruppi e sottogruppi di rilievo per il business sia il kmeans che il DBscan e sono stati messi a confronto per trovare i migliori raggruppamenti possibili[si prenda visione del report su cluster analysis].
- Frequent Pattern Mining: unico algoritmo di estrazione dei pattern frequenti utilizzato è stato FP growth, questa scelta è legata a diverse ragioni, in primo luogo FP growth risulta più efficiente nel gestire le risorse su disco durante l'elaborazione e in secondo luogo perché sia la fase di elaborazione e costruzione dei dati per adattarli all'algoritmo ha portato via parecchio tempo nonché è risultata dispendiosa anche l'esecuzione dell'algoritmo. [si prenda visione del report su frequent pattern mining]
- Classificazione: Per questo task come unico modello è stato scelto il Random Forest l'idea di un solo modello è quella di tenere il modello fermo è di fare in modo che i dati siano manipolati al meglio per ottenere un addestramento adeguato, con visione Data Centric AI. Tuttavia nonostante l'algoritmo di machine learning per fare classificazione sia unico sono state messe in atto 5 tecniche differenti per trattare il forte sbilanciamento che avevamo nel dataset.

5.2 Progettazione del Piano di Test

La progettazione del test per ogni uno dei task precedentemente descritti ha seguito strade diverse dettate dalle diverse esigenze.

- **Cluster Analysis:** L'idea qui è stata quella di andare ad ottimizzare i due algoritmi in base alla ricerca dei loro migliori parametri, in particolare il k ovvero numero di cluster per il k means e ϵ il raggio per trovare i core point e i border point per il DBscan, una volta posti entrambi ad ottimizzazione si sono calcolate le performance migliori su silhouette score, tuttavia poiché il silhouette score in quanto metrica non supervisionata non è molto indicativa della qualità del cluster, i cluster ottenuti sono stati sottoposti a tecniche di visualizzazione 2D tramite PCA e tsne per decretare se il cluster fosse effettivamente proficuo. [si prenda visione del report su cluster analysis e notebook].
- **Frequent Pattern Mining:** In questo task invece non avendo un algoritmo competitor ci siamo limitati a settare nel migliore dei modi le misure di supporto, confidenza e lift, in modo da strigare i requisiti e fare emergere dei pattern che fossero forti dal punto di vista semantico e non forti per numerosità che spesso si traduce in evento di associazione scontata. Per analizzare al meglio le regole estratte abbiamo diviso la ricerca in 3 tagli effettuati sul minimo supporto per l'estrazione dei pattern frequenti. I tagli sono stati i seguenti 1%, 3% e 5%, per ogni uno si sono applicati dei criteri in modo da filtrare le regole opportunamente per ritrovare solo regole che avessero una forza maggiore, i vari settori studiati prevedono le cause che portano all'abbandono, quelle che portano a variazioni di transazioni, ha tipologie di carta e fasce di modalità di transazione. [si prenda visione del report su frequent pattern mining]
- **Classificazione:** Qui invece siamo andati prima a testare la migliore tecnica per affrontare lo sbilanciamento per cui abbiamo messo a confronto con K-fold stratificata a 5 fold i seguenti approcci usando sempre il random forest:
 - Baseline class-weight differenti.
 - Tomek Links.
 - NearMiss.
 - Random under sampling + ensemble RF
 - SMOTE + undersample majority class

Questi modelli sono stati confrontati con una serie di batterie di metriche idonee allo sbilanciamento fornendo un report di classificazione dal quale è stato possibile andare a rilevare i migliori 2 modelli.

Trovati i migliori 2 modelli NearMiss e Random under sampling + ensemble RF, questi sono stati sottoposti a ottimizzazione tramite grid search con K-fold stratificata a 5 fold e previa ottimizzazione si è utilizzato un meccanismo di wrapper feature selection per andare a identificare il sottoinsieme di feature

più significative per l'ottimizzazione del modello. Infine questi modelli sono stati posti a confronto con le metriche per dichiarare il migliore.

5.3 Costruzione del Modello

La principale libreria usata è stata scikit-learn e il linguaggio di programmazione python per dettagli sulla costruzione del modello consultare i notebook (imbalanced_learning.ipynb e ottimizzazione.ipynb)

5.4 Valutazione del Modello

- Cluster Analysis: attraverso il silhouette score e con visualizzazione 2D tramite PCA e tsne[si prenda visione del report su cluster analysis].
- Frequent Pattern Mining: tramite supporto, confidenza e lift. [si prenda visione del report su frequent pattern mining]
- Classificazione: principalmente la scelta del modello migliore è stata presa basandosi sul recall più elevato per la classe minoritaria, ad ogni modo sono state utilizzate anche F1-score, Roc-Auc, Precision, Balanced-Accuracy.

Capitolo 6

Valutazione

6.1 Valutazione dei Risultati

- Cluster Analysis: Le tecniche di cluster applicate non hanno prodotto i risultati sperati, in particolare il cluster è stato eseguito su raggruppamenti di variabili diverse con solo risultati discreti per il gruppo logico-semantic di Utilizzo carta e per quello di abitudini transazionali o transazioni. Di seguito riportiamo i risultati ottenuti:

– Cluster su Utilizzo Carta:

```
Metrische KMeans (k=2):  
Silhouette: 0.469  
Davies-Bouldin: 0.871  
Calinski-Harabasz: 7474.6  
  
Statistiche Cluster KMeans:  
      Size Churned Churn_Rate  
Cluster  
0      1994      296      0.148445  
1      8133     1331      0.163654
```

Figura 6.1: Risultati del kmeans su grupo variabili utilizzo.




Figura 6.2: Risultati del kmeans visualizzati in 2D con PCA.




Figura 6.3: Risultati del kmeans visualizzati in 2D con tsne.

Infine riportiamo le descrizioni statistiche dei cluster individuati:

```
=====
CARATTERIZZAZIONE CLUSTER - Utilizzo (KMeans)
=====

--- CLUSTER 0 (n=1994) ---

Caratteristiche numeriche medie:
Credit_Limit: 24672.67 (media generale: 8631.95, diff: +185.8%)
Total_Revolving_Bal: 1117.22 (media generale: 1162.81, diff: -3.9%)
Avg_Open_To_Buy: 23555.45 (media generale: 7469.14, diff: +215.4%)
Avg_Utilization_Ratio: 0.05 (media generale: 0.27, diff: -82.6%)

--- CLUSTER 1 (n=8133) ---

Caratteristiche numeriche medie:
Credit_Limit: 4699.19 (media generale: 8631.95, diff: -45.6%)
Total_Revolving_Bal: 1173.99 (media generale: 1162.81, diff: +1.0%)
Avg_Open_To_Buy: 3525.19 (media generale: 7469.14, diff: -52.8%)
Avg_Utilization_Ratio: 0.33 (media generale: 0.27, diff: +20.3%)
=====
```

Figura 6.4: Descrizione statistica dei cluster ritrovati kmeans.

Commento interpretativo: Questi cluster ritrovati mettono in luce due differenti modalità di utilizzo della carta da parte dei clienti nel cluster0 troviamo clienti con limiti di credito alto e quindi clienti premium, con alta disponibilità alla spesa, ma un utilizzo basso della carta per gli acquisti “potrebbe essere che tali clienti pagano sempre in contanti data la buona condizione finanziaria”. L’altro cluster1 invece caratterizza clienti con un limite di credito basso che hanno una disponibilità di spesa ridotta, ma che utilizzano frequentemente la carta di credito “forse per promozioni o sconti sull’utilizzo maggioritario”.

– Cluster su Abitudini Transazionali:

```
Metrische KMeans (k=2):
Silhouette: 0.408
Davies-Bouldin: 0.878
Calinski-Harabasz: 3705.0

Statistiche Cluster KMeans:
      Size  Churned  Churn_Rate
Cluster
0      8916     1544    0.173172
1      1211       83    0.068538
```

Figura 6.5: Descrizione statistica dei cluster ritrovati kmeans.




Figura 6.6: Ottimizzazione del kmeans.




Figura 6.7: Visualizzazione 2D kmeans con PCA.




Figura 6.8: Visualizzazione 2D kmeans con tsne.

```

=====
CARATTERIZZAZIONE CLUSTER - Transazioni (KMeans)
=====

--- CLUSTER 0 (n=8916) ---

Caratteristiche numeriche medie:
Total_Trans_Amt: 3342.13 (media generale: 4404.09, diff: -24.1%)
Total_Trans_Ct: 59.74 (media generale: 64.86, diff: -7.9%)
Total_Amt_Chng_Q4_Q1: 0.76 (media generale: 0.76, diff: -0.4%)
Total_Ct_Chng_Q4_Q1: 0.71 (media generale: 0.71, diff: -0.2%)

--- CLUSTER 1 (n=1211) ---

Caratteristiche numeriche medie:
Total_Trans_Amt: 12222.76 (media generale: 4404.09, diff: +177.5%)
Total_Trans_Ct: 102.57 (media generale: 64.86, diff: +58.1%)
Total_Amt_Chng_Q4_Q1: 0.78 (media generale: 0.76, diff: +2.6%)
Total_Ct_Chng_Q4_Q1: 0.72 (media generale: 0.71, diff: +1.7%)

```

Figura 6.9: Descrizione statistica dei gruppi ritrovati.

Commento interpretativo: Questa volta il cluster0 mette in evidenza clienti con transazioni basse standard e senza variazioni nel quadrimestre osservato, mentre il cluster1 mostra clienti con alta frequenza e alto ammontare delle transazioni che effettuano.

Vediamo adesso i risultati ottenuti con il DBscan che in questo caso è risultato migliore del kmeans:

```

✓ Miglior eps: 0.6009 (percentile 98)
Silhouette: 0.480
Cluster: 3

Parametri finali DBSCAN:
eps: 0.6009
min_samples: 5
Cluster trovati: 3
Punti di rumore: 144 (1.4%)

Metriche DBSCAN:
Silhouette: 0.480
Davies-Bouldin: 1.611
Calinski-Harabasz: 1615.1

Statistiche Cluster DBSCAN:

```

Cluster	Size	Churned	Churn_Rate
-1	144	28	0.194444
0	9231	1599	0.173221
1	11	0	0.000000
2	741	0	0.000000

Figura 6.10: Risultati ottenuti con il dbscan.




Figura 6.11: Visualizzazione dei risultati dbscan in 2D con PCA.




Figura 6.12: Visualizzazione risultati dbscan 2D con tsne.

```
=====
CARATTERIZZAZIONE CLUSTER - Transazioni (DBSCAN)
=====

--- CLUSTER 0 (n=9231) ---

Caratteristiche numeriche medie:
Total_Trans_Amt: 3600.70 (media generale: 4422.56, diff: -18.6%)
Total_Trans_Ct: 61.62 (media generale: 65.21, diff: -5.5%)
Total_Amt_Chng_Q4_Q1: 0.75 (media generale: 0.75, diff: -0.3%)
Total_Ct_Chng_Q4_Q1: 0.70 (media generale: 0.70, diff: -0.8%)

--- CLUSTER 1 (n=11) ---

Caratteristiche numeriche medie:
Total_Trans_Amt: 1628.18 (media generale: 4422.56, diff: -63.2%)
Total_Trans_Ct: 31.91 (media generale: 65.21, diff: -51.1%)
Total_Amt_Chng_Q4_Q1: 1.21 (media generale: 0.75, diff: +61.4%)
Total_Ct_Chng_Q4_Q1: 1.92 (media generale: 0.70, diff: +174.2%)

--- CLUSTER 2 (n=741) ---

Caratteristiche numeriche medie:
Total_Trans_Amt: 14702.29 (media generale: 4422.56, diff: +232.4%)
Total_Trans_Ct: 110.39 (media generale: 65.21, diff: +69.3%)
Total_Amt_Chng_Q4_Q1: 0.77 (media generale: 0.75, diff: +2.8%)
Total_Ct_Chng_Q4_Q1: 0.75 (media generale: 0.70, diff: +6.8%)
```

Figura 6.13: Descrizione statistica dei gruppi ritrovati.

Commento interpretativo:

[si prenda visione del report su cluster analysis].

- Frequent Pattern Mining: Di seguito riportiamo le migliori regole ritrovate per prevezione dell'abbandono ad ogni modo per predeere completa visione dei pattern ritrovati si consiglia di osservare il codice con i risultati. [notebook frequent_pattern_mining.ipynb]


```

ANTECEDENTE (IF):
Variabili:
- Importo_Transazioni_Molto_Basse
- N_Transazioni_Freq_Molto_Rara
- Var_N_Transazioni_Minima

CONSEQUENTE (THEN):
Variabili:
- Stato_Cliente_Attrited Customer
- Tipo_Carta_Blue

INDICI DI ASSOCIAZIONE:
Supporto: 0.0331 (Frequenza congiunta del pattern)
Confidenza: 0.8272 (Probabilità che IF -> THEN)
Lift: 5.5146 (Quanto è migliore di una co-occorrenza casuale)
Leverage: 0.0271 (Differenza tra frequenza congiunta e attesa)
Conviction: 4.9179 (Relazione con la Confidenza)

```

Figura 6.14: Cause che portano all'abbandono e alla carta blue standard.

```

ANTECEDENTE (IF):
Variabili:
- Importo_Transazioni_Molto_Basse
- N_Transazioni_Freq_Molto_Rara

CONSEQUENTE (THEN):
Variabili:
- Stato_Cliente_Attrited Customer

INDICI DI ASSOCIAZIONE:
Supporto: 0.0341 (Frequenza congiunta del pattern)
Confidenza: 0.8195 (Probabilità che IF -> THEN)
Lift: 5.1007 (Quanto è migliore di una co-occorrenza casuale)
Leverage: 0.0274 (Differenza tra frequenza congiunta e attesa)
Conviction: 4.6495 (Relazione con la Confidenza)

```

Figura 6.15: Cause che portano all'abbandono.

```

ANTECEDENTE (IF):
Variabili:
- Importo_Transazioni_Molto_Basse
- N_Transazioni_Freq_Molto_Rara
- Var_N_Transazioni_Minima
- Tipo_Carta_Blue

CONSEQUENTE (THEN):
Variabili:
- Stato_Cliente_Attrited Customer

INDICI DI ASSOCIAZIONE:
Supporto: 0.0331 (Frequenza congiunta del pattern)
Confidenza: 0.8481 (Probabilità che IF -> THEN)
Lift: 5.2789 (Quanto è migliore di una co-occorrenza casuale)
Leverage: 0.0268 (Differenza tra frequenza congiunta e attesa)
Conviction: 5.5257 (Relazione con la Confidenza)

```

Figura 6.16: Cause che portano all'abbandono.

- Classificazione: utilizzate anche F1-score, Roc-Auc, Precision, Balanced-Accuracy.




Figura 6.17: Confusion Matrix per NearMiss.




Figura 6.18: Confusion Matrix per Ensemble.




Figura 6.19: Metriche di valutazione per i due modelli ottimizzati.

6.2 Revisione del Processo

Si potrebbe pensare di espandere e continuare la sperimentazione del progetto andando a destare dei diversi algoritmi di apprendimento e vedere se i risultati cambiano con quelli ottenuti o meno. In linea di massima i passi del Crisp-DM sono stati eseguiti correttamente con successo e nel rispetto dei criteri adoperati.

6.3 Definizione dei Prossimi Passi

Progettare l'esportazione del modello con il formato pickel nativo di python per renderlo operativo e utilizzabile dalla banca nell'immediato.

Capitolo 7

Conclusioni

Il seguente progetto ha permesso di andare a fare pratica con buona parte delle tecniche di data mining viste durante il corso e soprattutto ha permesso di metter in pratica la metodologia Crisp-DM nell'affrontare l'analisi di dati aziendali strutturando in modo formale e tecnico i requisiti, la pianificazione, l'implementazione, valutazione e revisione di tutto il processo analitico sviluppato per fornire una risposta congrua ai bisogni dello stack holder identificato nella banca. Questa esperienza ha permesso di andare ad affinare tecniche analitiche sia in fase di esplorazione dei dati per capire le caratteristiche dei dati manipolati sia in fase di predizione andando ad addestrare dei modelli di machine learning per classificazione.